

Aplicaciones Computacionales en Negocios

Nicolas Merener

Universidad Torcuato Di Tella

2026

Probabilidad II e intro Monte Carlo

hasta ahora

queremos estudiar sistemas para los que conocemos sus reglas locales de cambio (en el tiempo o el espacio) pero que son difíciles o imposibles de predecir analíticamente porque

- tienen muchas partes que se mueven
- shocks al azar

vamos a *simular* estos sistemas

generar muchos *caminos* donde cada uno representa una evolución futura del sistema

luego calcularemos estimadores de las cantidades que nos importen (valor esperado, varianza, etc) tomando promedios sobre muchos caminos

usaremos estos estimadores para tomar decisiones o analizar negocios

como un paso previo repasamos conceptos de probabilidad


distribución lognormal

la clase pasada vimos la **distribución normal**. sea **Z** una **variable aleatoria normal estándar**. definimos

$$X = e^{\mu + \sigma Z}$$

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln(x)-\mu)^2}{2\sigma^2}}$$

valor esperado = $e^{(\mu+1/2\sigma^2)}$



skewness y kurtosis

a veces nos interesa la forma de una densidad más allá de su media y varianza

media: "ubicación aproximada"

desviación estándar: "ancho o incertidumbre aproximada"

skewness: "asimetría"

Las dos fórmulas siguen la misma lógica:
estandarizás la variable y después elevás a una potencia.

$$\text{skew}[X] = E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{E[(X - \mu)^3]}{\sigma^3}$$

kurtosis: "chance de eventos extremos más allá de desviación estándar"

$$\text{kurt}[X] = E\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{E[(X - \mu)^4]}{\sigma^4} = 3$$


excess kurtosis definida como kurtosis - 3

la distribución Normal tiene excess kurtosis igual a cero $\text{kurtosis} - 3 = 3 - 3 = 0$


skewness

cola a la
izq

cola a la
derecha



kurtosis



distribuciones conjuntas

muchos sistemas tienen múltiples fuentes de incertidumbre

más de un input para analizar el molino de viento: X es velocidad del viento, Y es precio de la electricidad

y más de un output puede ser medido: $Profit_1, Profit_2, \dots$ son todas vbles aleatorias vistas desde hoy

la mayoría de los sistemas reales tienen decenas de vbles aleatorias. se necesita criterio y ciencia para elegir qué vbles modelar

técnicamente, una par de vbles conjuntamente distribuidas es una función del espacio de eventos S a $\mathbb{R}^2$.

luego, densidades en 2 o N dimensiones

Variable aleatoria: $X: S \rightarrow \mathbb{R}^1$
Par conjunto: $(X, Y): S \rightarrow \mathbb{R}^2$

Las dos coordenadas vienen del mismo resultado subyacente

ejemplo de función de probabilidad conjunta

función de probabilidad: $p(x, y) = P(X = x, Y = y)$

las vbles aleatorias discretas X e Y tienen distribución conjunta

	$x = 1$	$x = 2$	$x = 3$	$p_Y(y)$
$y = 1$	$3/12$	$1/12$	$3/12$	$7/12$
$y = 2$	$1/12$	$3/12$	$1/12$	$5/12$
$p_X(x)$	$4/12$	$4/12$	$4/12$	1.00

$$p_{X,Y}(1, 2) = 1/12.$$

la distribución marginal de Y (sumando sobre todos los valores posibles de X).

$$p_Y(y) = \begin{cases} \frac{7}{12} & \text{for } y = 1 \\ \frac{5}{12} & \text{for } y = 2 \\ 0 & \text{Otherwise} \end{cases}$$


en general

- $p_X(x) = \sum_y p_{X,Y}(x, y)$
- $p_Y(y) = \sum_x p_{X,Y}(x, y)$
- marginales se obtienen sumando sobre las otras variables.

$$p_X(x) = \sum_{\{y: p(x,y)>0\}} p(x, y)$$

vbles aleatorias continuas

- densidad conjunta de (X, Y) no es una curva sino una superficie, $f(x, y)$.
- masa de probabilidad es un volumen en vez de un área.



→ superficie

momentos condicionales

vbles conjuntamente distribuidas X e Y .

- para cada valor posible de X hay una distribución condicional de Y .
- cada distribución condicional tiene un valor esperado (media de la subpoblación).
- $E(Y|X = x)$ sería una predicción de Y si sabemos que $X = x$.

el valor esperado condicional de Y dado X es

$$E(Y|X = x) = \sum_y y p_{y|x}(y|x) \quad \text{o} \quad \int_{-\infty}^{\infty} y f_{y|x}(y|x) dy$$

y también se cumple que

$$Var(X) = E[Var(X|Y)] + Var(E[X|Y])$$

intuición?

covarianza

sean X e Y vbles aleatorias conjuntamente distribuidas con $E(X) = \mu_x$ y $E(Y) = \mu_y$. la covarianza entre X e Y es

$$\text{Cov}(X, Y) = E[(X - \mu_x)(Y - \mu_y)]$$

- si los valores de X que están por arriba de su media tienden a suceder con valores de Y por arriba de su media (y valores bajo la media de X con aquellos bajo la media de Y), la covarianza será positiva. $\begin{matrix} (+ \times +) = + \\ (- \times -) = + \end{matrix}$
- si valores de X arriba de su propia media tienden a coincidir con valores de Y debajo de su media, la covarianza será negativa.
- covarianza es una medida de variación conjunta.
- $\text{Var}(X) = E[(X - \mu_x)^2]$ as $\text{Cov}(X, X)$.

propiedades de covarianza

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

Si X e Y son independientes, $\text{Cov}(X, Y) = 0$

$\text{Cov}(X, Y) = 0$, *no implica* que X e Y son independientes.

$$\text{Cov}(a + X, b + Y) = \text{Cov}(X, Y)$$

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$$

$$\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$$

$$\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab\text{Cov}(X, Y)$$

Si $X_1, \dots, X_n$ son ind. $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i)$

correlación

medida de covarianza normalizada por la variabilidad intrínseca de X e Y


$$\text{Corr}(X, Y) = \rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

- $-1 \leq \rho \leq 1$
- no depende de la escala $\text{Corr}(aX, bY) = \text{Corr}(X, Y)$

correlación

corto plazo vs largo plazo. importa?

X e Y parecen bastante correlacionadas



ley de los grandes números

sea $X_1, X_2, \dots$ una secuencia de vbles aleatorias independientes e idénticamente distribuidas con media μ . Entonces, para cualquier $\epsilon > 0$ se cumple que

$$P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \epsilon\right) \rightarrow 0$$

a medida que

$$n \rightarrow \infty$$

si promediás muchas muestras independientes de una misma variable, ese promedio se acerca cada vez más a la media verdadera μ a medida que agregás muestras

intuición?

sirve esto para estudiar sistemas que involucran aleatoriedad?

teorema central del límite

sea $X_1, X_2, \dots$ una secuencia de vbles aleatorias independientes e idénticamente distribuidas con media μ y varianza finita σ^2 . sea $N(x)$ la distribución normal estándar con media cero y desviación estándar 1. Se cumple que

$$\lim_{n \rightarrow \infty} P\left(\frac{(X_1 + \dots + X_n)/n - \mu}{\frac{\sigma}{\sqrt{n}}} < x\right) = N(x)$$

Se acerca a la normal estándar

a medida que

$$n \rightarrow \infty$$

intuición computacional?

qué sucede con la media y varianza de una suma de variables i.i.d. a medida que agregamos términos?

intro a Monte Carlo

tenemos el **modelo de un negocio (complejo)**

$$Y = \text{Profit}(\text{Wind}, \text{PriceElec})$$

lo del molino

Sabemos cómo calcular $\text{Profit}(\cdot)$ pero no sabemos qué distribución sigue.

donde **no sabemos la distribución de Profit** . Queremos **calcular su valor medio**.

Supongamos que **sabemos generar muestras de $X = \{\text{Wind}, \text{PriceElec}\}$** y, **para cada una de ellas, calcular Y** .

entonces **generamos un N grande de muestras independientes de $\{X_i\}$ y calculamos $Y(X_i)$** . $X_i = \{\text{Wind}_i, \text{PriceElec}_i\}$, $i = \text{momento dado}$

por construcción, estas son i.i.d

Función que toma un profit y devuelve un número

funciones $h(Y)$ también son i.i.d, y supongamos con varianza finita

el **estimador de Monte Carlo es $\frac{1}{N} \sum_i^N h(Y(X_i))$**

promedia todos los resultados de $h(Y)$

simplemente el promedio $h(Y)$ sobre las muestras (o caminos) de X

h puede ser un molde para poner una función que estime esperanza, varianza...

Monte Carlo y convergencia

el estimador de Monte Carlo es un promedio de muestras i.i.d

entonces, por ley de los grandes números + teorema central del límite

$$\frac{1}{N} \sum_i^N h(Y(X_i)) \rightarrow E[h(Y)] + Z \frac{\sigma_h}{\sqrt{N}}$$

where Z is a standard normal random variable

^ error de estimación de MC

converge a la media $E[h(Y)]$ que nos interesaba

output de una simulación Monte Carlo

cómo implementamos estimadores Monte Carlo que sean útiles?

supongamos que Y es una variable aleatoria escalar (por ejemplo, la ganancia para nuestro negocio, que depende de un insumo aleatorio X)

$$\frac{1}{N} \sum_i^N h(Y(X_i))$$

- si $h(y) = y$, obtenemos $E[Y]$ Poner la función que quieras.
- si $h(y) = y^2$ y lo combinamos con $E[Y]$, obtenemos $Var[Y]$
- si $h(y) = 1_{\{a < Y < b\}}$, obtenemos $Proba(a < Y < b)$
- probabilidades condicionales?
- y más...

distribuciones vs muestreo

los **inputs a nuestros modelos de negocios** serán **variables aleatorias**, para las que **generaremos muchas muestras independientes para Monte Carlo**.

- **conocemos la distribución de un dado? cómo generamos muestras (físicamente)?**
- **conocemos la distribución de una moneda cargada? cómo generamos muestras?**
- **conocemos la distribución uniforme? cómo generamos muestras a partir de ella?**

saber que **una vble X tiene cierta distribución** (o sea **conocer la fórmula analítica de la distribución**) **no es equivalente a conocer un mecanismo** (físico o computacional) que **genere muestras** con esa frecuencia. **Cómo obtengo valores reales?**

además, las **computadoras clásicas son intrínsecamente deterministas**. solo vamos a **generar algo que se parezca al azar**.